

Curs bilingv de test pentru extragerea definițiilor și generarea întrebărilor

Document de validare pentru pipeline NLP + quiz generation

Acest document este conceput special pentru a testa: detectarea limbii, extragerea definițiilor, identificarea conceptelor, generarea întrebărilor în limba română și în limba engleză, tratarea termenilor englezi în propoziții românești, filtrarea zgomotului și rezistența la secțiuni non-definiționale.

Instrucțiune de folosire: documentul conține atât definiții curate, cât și secțiuni cu zgomot intenționat. Un sistem bun ar trebui să extragă definițiile reale și să ignore formulele, notele bibliografice, listele incomplete și pasajele procedurale.

1. Informatică / Computer Science

Română - definiții simple și formale

- Programarea orientată pe obiecte este o paradigmă de programare bazată pe obiecte care combină date și comportamente.
- Încapsularea reprezintă ascunderea detaliilor interne ale unui obiect și expunerea unei interfețe controlate.
- Polimorfismul înseamnă capacitatea unor obiecte diferite de a răspunde la aceeași interfață în moduri specifice.
- Moștenirea se referă la mecanismul prin care o clasă derivată reutilizează și extinde o clasă de bază.
- O structură de date este definită ca o modalitate organizată de stocare și accesare a datelor.
- O listă înlănțuită este alcătuită din noduri conectate prin referințe.
- Un compilator este utilizat pentru transformarea codului sursă într-o formă executabilă sau într-un cod intermediar.
- Un index este folosit în baze de date pentru accelerarea căutărilor pe una sau mai multe coloane.
- Un API are rolul de a permite comunicarea standardizată între două componente software.
- Un algoritm constă în o succesiune finită de pași neambigui care rezolvă o problemă.
- Termenul object oriented programming face referire la programarea orientată pe obiecte.

English - definitions

- A variable is a named storage location that can hold a value.
- A function can be defined as a reusable block of code that performs a specific task.
- A stack consists of elements organized according to the last in, first out principle.
- A queue is composed of elements processed according to the first in, first out principle.
- Recursion refers to a technique in which a function calls itself on smaller subproblems.
- A database index is used for improving lookup speed in a table.
- A hash table means a data structure that maps keys to values through a hash function.
- The role of version control is to track changes in files over time.

- A compiler can be described as a program that translates source code into another form.

Mixed-language cases

- Object oriented programming este un stil de programare în care obiectele modelează entități și comportamente.
- Dependency injection este utilizată pentru reducerea dependențelor rigide dintre componente.
- Encapsulation is a design principle that restricts direct access to internal state.

2. Geografie / Geography

Română

- Un continent este o întindere foarte mare de uscat delimitată de oceane sau de convenții geografice.
- Clima reprezintă media pe termen lung a condițiilor atmosferice dintr-o regiune.
- Un delta este formată din brațe de apă, canale, aluviuni și zone umede.
- Latitudinea se referă la distanța unghiulară față de Ecuator.
- Longitudinea se referă la distanța unghiulară față de meridianul de origine.
- Harta topografică este utilizată pentru reprezentarea detaliată a reliefului și a elementelor de la suprafață.

English

- A peninsula is a landform surrounded by water on most sides but connected to the mainland.
- A desert is a region characterized by very low annual precipitation.
- A glacier can be defined as a persistent mass of dense ice that moves under its own weight.
- A map scale refers to the relationship between a distance on a map and the corresponding distance on the ground.
- The role of a compass is to indicate cardinal directions relative to magnetic north.

3. Literatură / Literature

Română

- Metafora reprezintă o figură de stil prin care un termen este înlocuit cu altul pe baza unei asemănări implicite.
- Naratorul este vocea care relatează evenimentele dintr-un text epic.
- Un roman este definit ca o specie epică în proză de mare întindere, cu acțiune complexă și personaje numeroase.
- Tema literară se referă la ideea centrală sau la ansamblul de idei dominante dintr-o operă.
- Ritmul are rolul de a organiza succesiunea accentelor și a pauzelor într-un text poetic.

English

- A simile is a figure of speech that explicitly compares two things using words such as like or as.
- A narrator refers to the voice through which a story is told.
- A sonnet consists of fourteen lines arranged according to a specific poetic structure.
- Symbolism can be described as the use of concrete images to suggest abstract meanings.

4. Științe / Science

Română

- Fotosinteza este procesul prin care plantele transformă energia luminoasă în energie chimică.
- Un ecosistem este alcătuit din organisme vii și din mediul lor de viață aflate în interacțiune.
- Densitatea reprezintă raportul dintre masă și volum.
- Un atom este utilizat în chimie pentru descrierea unității fundamentale a unui element.
- ADN se referă la acidul dezoxiribonucleic, molecula care stochează informația genetică.

English

- Gravity is the force that attracts bodies with mass toward one another.
- An ecosystem means a community of organisms interacting with their physical environment.
- The role of chlorophyll is to absorb light energy for photosynthesis.
- A molecule is composed of two or more atoms chemically bonded together.
- The water cycle consists of evaporation, condensation, precipitation, and collection.

5. Secțiuni speciale pentru testare

5.1. Definiții care folosesc mai multe pattern-uri

- Un dicționar este o structură de date; termenul dictionary se referă la asocierea cheie-valoare.
- A polygon is a closed plane figure; the term perimeter refers to the total length of its boundary.
- Un server web este folosit pentru livrarea de pagini și resurse către clienți; rolul său este de a răspunde la cereri HTTP.
- A bibliography is a list of sources; it is used for documenting references in academic writing.

5.2. Cazuri mixte română + engleză

- Machine learning este un domeniu al inteligenței artificiale care permite sistemelor să învețe din date.
- A class în programarea orientată pe obiecte este un șablon pentru crearea obiectelor.
- Design pattern se referă la o soluție generală și reutilizabilă pentru o problemă de proiectare frecventă.
- The term garbage collection se referă la procesul automat de eliberare a memoriei neutilizate.

5.3. Zgomot intenționat care ar trebui ignorat

Exemplu de calcul:

$$y = x * 2 + 5$$

$$\Delta w = \alpha * x * e$$

Pasul 1: se calculează gradientul.

Pasul 2: se determină eroarea.

Iterația 3: valoare = 0.125.

ISBN 978-1-4028-9462-6

2nd edition, Academic Press, vol. 4

5.4. Formulări care nu sunt definiții, ci explicații sau instrucțiuni

- În acest exemplu se calculează rezultatul pentru trei valori diferite.
- Apoi se determină media și se obține eroarea finală.
- Pasul următor constă în actualizarea variabilelor din tabel.

6. Set suplimentar de definiții curate pentru generarea întrebărilor

- Un browser este un program utilizat pentru accesarea și afișarea paginilor web.
- HTTP reprezintă un protocol de comunicare pentru transferul resurselor pe web.
- A library is a collection of reusable code.
- A framework can be defined as a software platform that provides structure for application development.
- Un meridian este o semicerc mare care unește cei doi poli geografici.
- Un vers este un rând dintr-o compoziție poetică.
- A thesis refers to the central claim or argument advanced in a text.
- Un vector este utilizat în matematică pentru reprezentarea unei mărimi care are modul, direcție și sens.
- An operating system is the software layer that manages hardware resources and provides services to applications.
- Caching means storing frequently accessed data in a faster layer for later reuse.
- Un personaj principal este personajul în jurul căruia se dezvoltă în mod dominant acțiunea unei opere.
- Un estuar este format din zona de întâlnire dintre apele dulci ale râului și apele sărate ale mării.

7. Observații finale

Definițiile din acest document sunt formulate deliberat în mai multe stiluri: „este”, „reprezintă”, „înseamnă”, „se referă la”, „este alcătuit din”, „are rolul de”, „is”, „means”, „refers to”, „consists of”, „is used for”. Scopul este testarea completă a pipeline-ului de extragere și a generatorului de întrebări.

Dacă sistemul funcționează bine, el ar trebui să extragă concepte precum: programarea orientată pe obiecte, encapsularea, clima, latitudinea, metafora, fotosinteza, gravity, map scale, narrator, browser, HTTP, caching și operating system. În același timp, el ar trebui să ignore formulele, ISBN-ul, notele de ediție și secțiunile procedurale.